

1 반갑습니다, 악성재고 및 판매여부 예측을 주제로 머신러닝 프로젝트를 진행한 4조 마당을 나온 수탉입니다. 저는 발표를 맡은 여혁수입니다.

2 발표 순서는 이렇습니다. 프로젝트 개요부터 분석 배경, eda, 사용한 모델에 대한 설명과 분석결과, 한계점까지 말씀드리겠습니다.

3팀원 역할인데요, 형식적인 감이 없지 않아 있긴 하지만 모두가 최선을 다해줬기에 지금 이 자리에 서있을 수 있는 것 같습니다.

4프로젝트 개요는 크게 4개 부분으로 나눠서 이렇게 나타내보았습니다.

5 12월 6일 부터 프로젝트 시작해서 오늘까지 8일 동안 쉬지 않고 달려왔습니다.

6 저희가 이번 프로젝트에서 주목한 것은 바로 재고입니다. 뭔가를 판매하는 기업이라면 재고는 항상 신경써야 하는데요, 왼쪽의 표는 기업의 재무 상태를 나타내는 대차대조표입니다. 여기서 핵심 자산 중에 하나가 바로 이 재고자산입니다.

7 애플도 1996년 재고 문제로 한때 파산 직전까지 몰렸는데요, 현 CEO인 팀 쿡이 당시 애플에 합류하면서, 7개월 만에 재고를 30일치에서 6일치로 줄였고, 1년이 될 때는 2일치로 줄여 결과적으로 매출 개선과 운영 효율성을 크게 높였고, CEO 자리까지 오는 데에 이러한 업적이 큰 영향을 주었습니다. 또한 이 사례는 재고 관리는 기업의 성패를 좌우하는 경영파트가 될수 있음을 보여주고 있습니다.

8 다음으로 이론적으로 재고 관리의 중요성에 대해 말씀드리겠습니다. 재고 관리는 기업 운영에 있어 빠질 수 없는 요소라 할 수 있습니다. 재고 과잉과 자원 낭비를 방지하여 비용을 절감할 수 있고, 고객이 필요로 할 때 제품을 즉시 제공함

으로써 고객 만족도를 높일 수 있습니다. 또한, 구매 및 생산 계획을 효율적으로 수립할 수 있고, 매출 감소에 대한 위험도 재고관리를 통해 커버할 수 있습니다.

9 또한 재고를 과잉 보유하는 것도 문제가 될 수 있습니다. 과도한 재고로 인해 관리 및 유지보수 비용 증가하면 다른 분야에 사용될 예산이 줄고, 생산 및 직원 고용까지 감소하게 되어, 경기 불황 및 소비 위축으로 이어지는 파멸적인 악순환을 만들어낼 수 있습니다.

10 이렇게 쌓인 수요 없는 재고를 바로 '악성재고'라고 부릅니다. 악성재고는 기업의 원활한 생산 활동을 위한 의도적인 재고가 아닌, 앞으로 사용될 가능성이 거의 없는 재고를 말하는데요, 예를 들어 노트북이나 스마트폰처럼 유행에 민감한 제품들은 시즌을 놓치면 판매가 어려워지고 유동성이 떨어지게 됩니다. 또 의류처럼 시장 변화가 빠른 제품군은 상품 가치가 급격히 하락하며 처분이 어려워질 수도 있습니다. 회계적으로도 다양한 요인으로 가치가 하락한 진부화된 자산과 악성재고는 기업에 큰 부담으로 작용합니다.

11 최근 뉴스를 보면 많은 기업들이 악성재고로 인해 어려움을 겪고 있다는 것을 알 수 있습니다. 이번 겨울, 다들 패딩 장만하셨나요? 저는 3년 정도 숏패딩을 입고 있는데, 겨울 패션제품에 대한 구매력이 최근에 많이 떨어져서 재고가 쌓이고 있습니다. 그리고 LP판은 말할 것도 없을 것 같구요. 쇼핑몰 평균 악성재고 20%, 그리고 유통업체 50곳이 재고자산으로 울고 웃었다 이런 것들이 재고관리의 심각성을 말해줍니다.

12 이러한 배경에서 저희 팀은 악성재고를 식별하고, 판매여부를 결정하는 요소들을 찾아내어 효율적인 재고 관리 측면에서 기업의 의사결정에 도움을 주고자 합니다.

13 다음으로는 데이터 소개부터 EDA 파트 설명 드리겠습니다.

14 저희가 사용한 데이터는 캐글에서 가져온 것으로, 19만여개 14개의 열로 구성되어 있습니다. 재고타입 기준으로 활성재고가 62%, 악성재고가 38%로 구성된 데이터라고 할 수 있겠습니다.

15 컬럼 단위로 데이터 설명을 하자면, FileType 변수는 재고유형인데요, 값이 Historical이면 악성, active이면 활성재고라고 보시면 되겠습니다. SKU_number라고 상품의 고유ID 변수가 있고요, SoldFlag와 SoldCount는 각각 제품의 판매여부, 그리고 판매량을 나타냅니다. 다음으로 MarketingType 변수는 값이 D또는 S인데, D면은 디지털 마케팅, S는 스탠다드라서 일반적인, 혹은 오프라인 마케팅이라 볼 수 있겠습니다. ReleaseNumber와 NewReleaseFlag는 각각 제품의 출시 횟수 그리고 신제품 출시 여부를 의미합니다. 다음으로 StrengthFactor는 판매강도지수인데, 값이 높을수록 판매가 어려운 제품이라고 보시면 되겠습니다. PriceReg는 정가, ReleaseYear는 제품의 출시 연도, ItemCount는 재고량, LowUserPrice는 제품의 최저소비자 가격, LowNetPrice는 이 제품으로 기업이 얻을 수 있는 최소한의 순수익을 의미합니다.

16 다음으로는 EDA를 진행했습니다. EDA로 몇 가지 중요한 점을 발견했습니다.

17 먼저, 판매 여부와 판매량 변수에 결측치가 있었는데, 결측치인 데이터는 모두 활성재고 데이터였습니다. 어떻게 처리가 되었는지는 모델링 파트에 피쳐 선택 슬라이드에서 다루도록 하겠습니다.

18 그리고, 같은 제품인데 활성재고도 있고, 악성재고도 같이 있는 경우가 13만 개 정도 있었습니다. 빨간 박스 안에 변수가 재고타입과 제품번호인데요, 제품번호는 동일한데 Active와 Historical로 별개의 데이터로 나뉘져 있는 것을 볼 수 있습니다. 아마도 신제품이 출시가 되면서 전략이 효과적이었고, 활성재고가 되면서 이전에 제품은 악성재고화된 것이 아닌가 추정을 했습니다.

19 반대로 활성재고만 존재하거나 악성재고만 존재하는 제품도 있었는데요, 빨간 박스 안에 컬럼은 각각 판매여부와 판매량 변수인데요, 결측치 또는 0만 있는 것을 볼 수 있습니다. 활성재고는 전부 결측치, 악성재고는 99%가 값이 모두 0인 것으로 즉 판매가 되지 않는 제품이라는 것을 확인을 했구요, 그렇기 때문에 활성재고의 경우 상품이 계속 판매가 잘 되고, 악성재고는 인기가 너무 없고, 살아날 희망도 없는 그런 재고라고 추정을 했습니다.

20 또한 저희는 분석 프로젝트의 완성도를 높이기 위해 기존 변수로 간단한 사칙연산을 통해서 의미가 있을 법한 파생 변수들을 만들었습니다. 재고가치, 재고가 소진될 때까지의 추정기간, 현재 재고의 보관된 기간, 제품의 할인율, 재고 회전율 이렇게 5개 정도 만들어봤습니다.

21 다음은 데이터 분석입니다. 데이터 분석으로는 재고 관리 분야에서 많이 쓰이는 ABC분석을 해보았습니다.

22 ABC 분석 기법은 재고 관리에서 많이 활용되는 방법으로, 재고 품목을 누적매출 구성비에 따라 A, B, C 세 가지 그룹으로 분류하여 효율적으로 관리하는 데에 목적이 있습니다.

A 등급은 가장 중요한 품목으로, 재고 데이터는 일반적으로 상위 20%의 품목이 전체 기여도의 70~80%를 차지합니다. 이 품목들은 기업 매출에 큰 영향을 미치기 때문에 신속하고 정확한 관리가 필요합니다. B 등급은 중간 중요도 품목으로, 재고의 적정 수준을 유지하는 것이 중요하구요. 마지막으로 C 등급은 덜 중요한 품목으로, 재고를 최소화하여 관리 비용을 절감하는 것이 포인트라 할 수 있겠습니다.

23 ABC분석을 저희 데이터에도 적용을 해보겠습니다. 먼저, 소비자 가격에 판매량을 곱하여 각 품목의 매출액을 계산합니다. 이후 매출액을 기준으로 내림차순으로 정렬하고, 각 품목의 매출액이 전체에서 차지하는 비율을 누적하여 기록합니다.

오른쪽 밑에를 보시면 누적매출 기준에 따른 등급이 나와있는데, 우선 매출이 가장 높은 제품부터 누적 매출액 비율 70%를 차지하는 것까지가 A등급으로 분류가 되구요, B 등급은 70~90%, C등급이 나머지 90~100%에 해당합니다. 이렇게 기업은 품목별 매출 기여도를 명확히 파악하고, 등급에 따라 차별화된 관리 전략을 수립할 수 있습니다.

24 다음은 등급별로 데이터 구성비가 어떻게 되었는지 말씀드리겠습니다.

사실 ABC분석은 파레토법칙에서 유래된 기법이라 파레토법칙에 대해서 먼저 알아야하는데요, 파레토법칙은 다양한 사업분야에서 기여도의 대부분이 소수의 요소들에 의존하는 현상을 말합니다. 그래서 80:20을 일반적으로 많이 얘기하는데요, 저희 데이터는 오른쪽 바차트를 보시면 크게 등급별 구성비 차이가 나지 않는 것을 볼 수 있습니다. 특히 A등급이 30%를 구성하는 것으로 봤을 때, 매출 기여도가 높은 제품이 다양하고 넓게 분포가 되어있음을 알 수 있었습니다.

25 다음으로는 등급에 따라서 평균적으로 의미있는 차이가 나는 변수를 기반으로 분석을 해보겠습니다. 출시횟수의 경우, 상위등급으로 갈수록 높게 나타나는데요, 그렇기 때문에 많은 재출시로 기능적이나 외적으로 업데이트를 한 것이 소비자들의 구매를 유도한다고 해석할 수 있었습니다.

26 다음으로 판매강도지수는 반대로 등급이 낮을수록 값이 높아지는 걸 볼 수가 있습니다. 처음에는 판매강도지수가 정확히 뭘 의미하는 건지 조금 헷갈렸는데 이 차트를 보고 판매가 어렵고 쉬운 정도를 나타내는 거라고 확신을 하게 되었습니다.

27 다음으로 기업이 책정한 정가의 경우 등급이 높을수록 올라가는 모습인데요, 고가의 제품이 매출 기여도가 높다는 의미이고 소비자가격도 오른쪽 차트를 보시면 마찬가지로 등급이 높을수록 올라가는데요, 종합해서 얘기를 해보자면 기업이 단가가 높은 제품에 상대적으로 더 높은 가격을 책정해서 해당 제품에 대해 더 높게 기대 수익률을 설정한다고 볼 수 있을 것 같습니다.

28 마지막으로 할인율, 그리고 회전율도 높은 등급일수록 값이 높아지는 것을 볼 수가 있습니다. 등급이 높은 제품일수록 할인 프로모션이 더 파격적이고, 이러한 전략에 따라서 소비자들의 구매가 촉진되고, 그에 따라 매출도 오르니 분류되는 등급도 올라가고, 회전율도 개선되는 그런 모습이라고 볼 수 있을 것 같습니다.

29 이렇게 분석해본 결과는 프로젝트 목표와 일맥상통하는 부분이 있습니다. 예를 들어, 이미 악성재고이거나 악성재고로 될 가능성이 높은 것을 모델링을 통해 알아냈는데, 해당되는 제품군이 너무나도 많다면 결국 기업은 우선 순위를 매겨서 재고 관리 전략을 세워야 할 것입니다. 이 때 ABC 분석으로 나온 등급 데이터까지 있다면 등급이 좋은 제품부터 우선적으로 해결한다는 그런 전략을 세울 수가 있는 것입니다.

마지막으로 ABC분석과 예측 모델링이 결합되어 기업의 재고 관리 전략에 도움을 줄 수 있다는 결론을 내보았습니다.

30 이제 모델링 파트로 넘어가보도록 하겠습니다. 저희는 2가지 모델을 만들었는데요, 먼저 소개드릴 모델은 해당 제품이 악성재고인지 아닌지 분류하는 모델입니다.

31 저희가 강의에서 배운 것 중에 분류에 특화된 모델 5개를 선정했습니다. 우선 확률 기반으로 회귀모델에서 나온 값을 시그모이드 함수 거쳤을 때, 0.5보다 크면 1, 아니면 0으로 분류하는 로지스틱 회귀 모델 사용했습니다. 직관적으로 특정 변수에 대한 기준에 따라 2갈래로 계속해서 갈라지는 의사결정트리, 거리 계산해서 가장 가까운 N개에서 가장 많이 분류가 되는 값을 따라가는 KNN, 의사결정트리를 여러개 합쳐 앙상블하는 랜덤포레스트, 랜덤포레스트와 유사하지만 부스팅기법이 적용된 XG부스트 이렇게 5개를 선택했습니다.

32 독립변수를 선택하기 위해 종속변수를 제외한 모든 변수를 독립변수로 해서 모델 학습을 했습니다. 그 결과 정확도가 100%가 나왔고, 판매여부와 판매량 변

수가 종속변수를 모두 결정한다는 것을 알게 되었습니다. 그래서 독립변수에서 제외를 하고, 이와 함께 인덱스의 의미만 갖는 변수도 제외하고 모델링 진행했습니다.

33 먼저 로지스틱 회귀 모델의 학습 결과입니다. 맨아래쪽에 그리드서치를 통한 찾은 최적의 하이퍼파라미터가 있습니다. 디폴트 값이 유지된 것을 제외하고 간략히 설명하자면, C값을 낮춰서 좀더 강하게 가중치를 표준화했고, 정규화도 ridge에서 lasso로 바꾼 것이 더 성능이 좋았습니다. 정확도는 오른쪽 상단에 약 81%로 나타나고 있고, 중간에 빨간박스를 보시면 활성 재고에 대한 리콜값이 0.63으로 상대적으로 낮게 나왔는데, 약 2:1로 악성재고인 데이터가 조금 더 많은 것이 영향을 주었을 것으로 생각했습니다.

34 그리고 각 독립변수에 부여된 가중치를 확인하면서 마케팅 타입과 신제품 출시 여부가 학습에 영향을 많이 미쳤다는 것을 확인했습니다. 또한 로지스틱 회귀에서 알아볼 수 있는 오즈 레이쇼를 통해 마케팅 방식이 디지털이면 활성재고일 확률이 그렇지 않을 때보다 2.3배 높고, 신제품 출시를 한 적이 있는 제품은 활성재고일 확률이 그렇지 않은 것보다 2.5배 높았다는 인사이트를 낼 수 있었습니다.

35 다음은 의사결정트리입니다. 하이퍼파라미터는 아래쪽에 나와있는 것과 같이 덱스 8 정도가 최적이었습니다. 정확도는 약 88%로 나타났습니다. 마찬가지로 활성 재고에 대한 리콜값이 0.76으로 약간 낮게 나왔으며, 변수 중요도는 재고가치 변수가 0.7로 가장 높게 나왔습니다.

36 KNN에서는 주변 15개를 고려한 모델을 선택되었고, 정확도는 약 84%로 나타났습니다. 역시나 동일하게 낮게 나온 리콜값이 있었습니다.

37 랜덤포레스트는 최대깊이 15인 의사결정 트리 40개를 앙상블하는 것으로 최적의 하이퍼파라미터를 찾을 수 있었고, 정확도는 약 89%입니다. 이전 모델들과 다르게 활성재고에 대한 리콜값도 0.81로 준수했습니다.

38 마지막으로 Xgboost의 하이퍼파라미터는 아래와 같습니다. 정확도는 90.4%로 사용 모델 중 가장 높았고, 재고가치가 압도적인 중요도를 보였던 의사결정트리, 랜덤포레스트와 다르게 재고가치, 최저소비자가격, 마케팅타입이 고르게 학습에 영향을 주었습니다.

39 정리하자면, 5개의 모델이 꽤 정확도 면에서 꽤 의미있는 차이가 있었고, 랜덤 포레스트와 XGBoost가 실제로 활용될 수 있을 정도의 우수한 성능을 보였습니다.

40 가장 성능이 좋았던 XG부스트의 변수 중요도를 막대 그래프로 나타내었고, 악성 재고의 여러 특징을 살펴보았습니다. 변수 중요도 상위 3개는 재고가치와 최저소비자가격, 마케팅타입이었습니다. 종속변수와 각 변수가 양의 상관관계를 갖는지, 음의 상관관계를 갖는지 확인하여 비싼 제품일수록 악성재고화될 가능성이 높고, 오프라인보단 온라인 마케팅이 좀 더 활성재고화에 효과적이라는 결론을 내볼 수 있었습니다.

41 다음은 악성재고에 대해서 판매 여부를 예측해보도록 하겠습니다.

42 악성재고는 판매되지 않은 것이 판매된 것보다 5배나 더 많습니다. 그래서 데이터를 오버샘플링하지 않으면 판매여부 예측을 판매되지 않은 데이터를 중심으로 학습을 해버려서 빨간박스 안에 있는 판매된 제품 데이터에 대한 예측 성능이 0.55와, 0.09로 위쪽에 있는 정확도 83프로와 너무나도 큰 차이가 나는 것을 발견했습니다.

그래서 저희는 불균형 데이터셋에서 소수 클래스의 인공 데이터를 생성하는 방법인 smote 라이브러리를 사용했습니다. 스모트는 kNN을 기반으로 인접한 데이터 포인트 사이에 새로운 데이터를 생성하여 최대한 합리적으로 데이터의 균형을 맞추는 식으로 동작을 합니다.

43 오버샘플링 적용해서 불균형했던 비판매와 판매 비중이 1:1로 동일하게 만들었습니다.

44 판매여부 예측에 대한 모델링 결과입니다. 먼저 로지스틱 회귀에서는, 실제로 판매가 된 데이터에 대한 예측 성능이 오버샘플링 이전보다 확연히 개선된 것을 확인할 수 있습니다. 우측 상단에 출력한 변수 가중치로 봤을 때, 마케팅타입과 재입고여부 변수가 모델 학습에 영향을 많이 주었음을 알 수 있습니다.

45 상단에 best 파라미터 보시면 다른 건 모두 default이고 C값이 0.001인 것이 최적 파라미터로 선정되었습니다. C값을 통한 가중치 규제가 강하게 된 것이 성능이 좋았습니다.

46 의사결정트리에서는 약 73%의 정확도를 보였으며, 전체적인 성능지표가 비슷했고, 마케팅타입과 판매강도지수가 높은 변수중요도를 보여주었습니다. 최대깊이 10, 그리고 지니계수로 평가한 것이 최적 하이퍼파라미터로 나왔습니다.

47 KNN에서는 주변 7개의 데이터를 사용해 학습했고, 모델의 정확도는 약 76%였습니다. 약간 신기했던건 디폴트값인 유클리드 거리로 계산한 것보다 절대값 기반으로 맨해튼 거리를 켜 것이 최적 하이퍼파라미터로 나왔다는 점입니다.

48 랜덤포레스트에서는 약 80%의 정확도를 보여주었습니다. 오버샘플링을 한 뒤의 데이터를 사용했기에 클래스 불균형 데이터에 대한 랜덤포레스트의 강점은 잘 드러나지 않았다고 생각합니다. 이전 모델들과 다르게 정말 다양한 변수들이 고루고루 중요하게 학습에 작용을 했습니다. 최대깊이 10에 최소 3개이상으로 노드가 갈라져야하는 조건이 최적 하이퍼파라미터로 선정되었습니다.

49 마지막으로 xgboost입니다. 오차를 개선해나가며 더 좋은 모델에 계속해서 가중치를 주기 때문에 다른 모델보다 전반적으로 좋은 성능을 나타냅니다. 정확도는 약 82%로, 마케팅타입이 압도적으로 학습에 큰 영향을 주었습니다. 그리고 모델 300개로 부스팅하고, 감마값 0.1을 줘서 과적합을 방지한 것이 최적의 하이퍼파라미터였습니다.

50 개별 모델에 성능을 정리해보자면 이렇습니다. xgboost가 다시 한번 모든 성능지표에서 1위를 하며 왕관을 받았습니다.

51 이대로 모델링을 끝내기에는 Xgboost가 그냥 좋다는 결론이 싫어서 수업 때 배운 앙상블을 활용해보았습니다. 판매 여부 예측 모델에 한해서 voting 방법을 사용해보기로 했는데요, Voting은 앞서 나온 개별 모델의 예측값이 투표가 되어 다수결로 최종 예측 결과를 생성하는 방식입니다.

52 결과를 말씀드리자면, 각 모델의 정확도보다 향상된 약 83%의 정확도를 나타냈습니다. 각 개별 모델이 데이터를 다른 관점에서 학습했기 때문에 성능이 향상했고, 여러 성능지표 값에 차이 없이 학습이 고루고루 잘 되었음을 알 수 있었습니다.

53 다음은 모델 별 하이퍼파라미터를 변경했을 때 학습 시간과 정확도 라인그래프로 나타낸 것입니다. Xgboost, 랜덤포레스트는 상대적으로 긴 학습시간을 가지지만 높은 성능을 보였고, 그 중에서도 Xgboost가 라인 그래프에서 빨간색인데, 랜덤포레스트인 초록색보다 빠른 속도로 학습 정확도를 높이면서 학습시간 대비 효율마저도 뛰어난 모습을 보여주고 있습니다. 의사결정트리, knn의 경우 학습시간은 짧았으나 대체로 낮은 성능을 보여주었습니다. 조정했던 하이퍼파라미터는 오른쪽 아래에 있는데요, 각 모델별로 빠지면 안되는 핵심 하이퍼파라미터 하나를 조정했다고 보시면 될 것 같습니다.

54 우선 로지스틱은 그래프에서 파란색 선으로 나타나고 있습니다. 반복횟수가

커질수록 학습시간도 늘어나고 정확도도 증가하지만, 후반부에서 정확도가 감소하며 과적합 되는 구간을 보여주고 있습니다. 의사결정트리는 주황색 선인인데요, 정확도가 왔다갔다 하는 걸보니 최적의 트리 깊이가 존재함을 알 수 있습니다. 랜덤 포레스트와 XGBoost는 각각 초록색, 빨간색 선으로 나타나고 있습니다. 또한 둘다 동그라미 친 부분에서 과적합이라고 하기에는 애매하지만 학습이 수렴하는 구간이 나타나고 있습니다. 마지막 KNN은 의사결정트리와 유사하게 적절한 이웃으로 볼 데이터 개수가 있다는 것을 알 수 있습니다.

55 모델링 결론을 말씀드리겠습니다. 우선 Voting 앙상블 모델이 가장 성능이 좋았고, XGBoost와 voting 모델의 예측값이 83.4%로 가장 많이 일치했습니다. 그래서 XGboost에서 변수 중요도를 출력해봤더니 마케팅 타입과 신제품 출시 여부가 판매 여부 예측에 가장 큰 영향을 주었음을 알 수 있었습니다. 그래서 이를 바탕으로 온라인 마케팅과 신제품 출시가 악성 재고의 판매에 촉진할 수 있다는 인사이트를 낼 수 있었습니다.

56 모델링 과정을 리뷰해보자면, 악성재고 분류는 XGBoost, 판매여부 예측은 Voting 앙상블 모델이 가장 좋았다고 정리할 수 있을 것 같습니다.

57 다음으로 기대효과에 대해 설명드리겠습니다.

보시는 것과 같이 모델링을 통해 알아본 학습에 중요했던 변수를 몇 개 뽑아서 의사결정 트리를 만들수가 있습니다. 이러한 의사결정 지원을 통해 기업의 재고 관리 시스템을 정교하게 만들 수 있습니다.

58 이외에도 재고 관리 효율성 향상, 마케팅 및 프로모션 효율성 향상, 비용 절감 등의 효과를 기대할 수 있습니다.

59 다만, 한계점도 몇 가지 있습니다.

먼저, 재고의 상황이 특수한 산업이라면 모델을 바로 적용하기에 어려울 수 있다

는 우려가 있습니다. 또한 판매 여부의 정확도는 약 83%로 비즈니스에 적용하기에는 아직은 위험합니다. 마지막으로, 다른 산업에 대한 가용 데이터가 없어 모델이 일반적으로 적용 가능한지, 유효한 모델인지를 확인할 수 없었습니다.

이런 아쉬움을 가지고, 데이터의 부족을 해결하고 모델의 성능을 끌어올리기 위한 방안을 추후 연구 프로젝트를 통해 생각해보고자 합니다.

60 이상으로 발표 마치겠습니다. 감사합니다.